MODELAGEM PREDITIVA DA VALORIZAÇÃO IMOBILIÁRIA EM CHAPECÓ/SC

Comparação de algoritmos de aprendizado de máquina

Ana Carla Londero Cazarotto[1], Álvaro Gianni Pagliari[2]

RESUMO

Este trabalho investigou se é possível estimar o valor de casas e apartamentos em Chapecó/SC, hoje e ao longo dos anos, com aprendizado de máquina aplicado a anúncios públicos. Foram coletados, por *web scraping*, 46.383 registros de oito imobiliárias entre março e agosto de 2026, que resultaram em 3.242 casas e apartamentos válidos após a limpeza. A análise exploratória mostrou preços muito assimétricos, a área e o bairro como principais determinantes e preços anunciados rígidos: 95,9% não mudaram entre coletas consecutivas. Como cinco meses de anúncios não medem valorização, simulou-se um histórico de 2016 a 2025 com um índice que combina a inflação (IPCA) e o custo da construção (INCC). Vinte e duas combinações de algoritmo e alvo e um *ensemble* foram comparados pelo erro percentual absoluto mediano (MdAPE), com validação cruzada agrupada por imóvel e erro medido apenas nos preços reais. Os modelos de árvores e o TabPFN foram os melhores, com pequena diferença. Entre os que podem ser publicados, venceram em apartamentos um *ensemble* de Random Forest e XGBoost (MdAPE de 13,1% e R^2 de 0,781 no teste) e em casas o TabPFN 3.5 (MdAPE de 18,7% e R^2 de 0,540). A valorização estimada foi de +4,33% ao ano para apartamentos e +4,17% para casas, e os resultados foram publicados em uma interface web. A abordagem é viável como apoio à decisão, mas a valorização passada é uma hipótese que ainda precisa ser validada com transações reais.

Palavras-chave: Aprendizado de máquina. Mercado imobiliário. Precificação de imóveis. Valorização imobiliária. *Web scraping*.

1 INTRODUÇÃO

Saber quanto vale um imóvel, e quanto ele pode valer daqui a alguns anos, é uma dúvida comum de quem compra, vende ou investe. Em cidades de médio porte como Chapecó, no oeste de Santa Catarina, essa resposta depende quase sempre da experiência de corretores, porque os índices de preços de imóveis existentes cobrem apenas as grandes capitais. Ao mesmo tempo, as imobiliárias da cidade publicam diariamente milhares de anúncios com preço, área, número de quartos e bairro, um volume de dados que pode ser organizado e analisado de forma sistemática.

Diante disso, este trabalho parte de duas questões: é possível construir, a partir de anúncios coletados automaticamente, um modelo que estime o valor de casas e apartamentos em Chapecó com erro aceitável? E, como a coleta cobre poucos meses, de que forma é possível estimar coerentemente quanto esse imóvel valia nos anos anteriores e quanto pode valer nos próximos? Complementarmente,

[1] Graduanda em Sistemas de Informação pela UNOESC; Chapecó; ana.cazarotto@unoesc.edu.br.
[2] Professor orientador do curso de Sistemas de Informação da UNOESC; Chapecó; alvaro.pagliari@unoesc.edu.br.

busca-se identificar quais variáveis mais influenciam o preço e qual algoritmo de aprendizado de máquina apresenta o melhor desempenho para os dados disponíveis.

A pesquisa se justifica pela ausência de um indicador de preços para o município, pela relevância econômica do setor imobiliário local e pela possibilidade de oferecer uma ferramenta gratuita e transparente de apoio à decisão. Do ponto de vista acadêmico, o trabalho aplica e compara técnicas de aprendizado de máquina em uma base regional construída do zero, documentando também as limitações encontradas, como a rigidez do preço anunciado.

O objetivo geral é comparar algoritmos de aprendizado de máquina para estimar o valor atual e projetar a valorização de casas e apartamentos em Chapecó/SC. Os objetivos específicos são: coletar e organizar anúncios de imobiliárias locais; realizar a limpeza e a análise exploratória dos dados; treinar e comparar modelos de regressão com métricas adequadas; construir uma estimativa de valorização baseada em índices oficiais; e disponibilizar os resultados em uma interface web. O trabalho seguiu as fases do CRISP-DM, que também organizam a descrição do método e dos resultados, do entendimento do problema e dos dados até a publicação dos modelos.

2 REVISÃO BIBLIOGRÁFICA

2.1 PRECIFICAÇÃO E VALORIZAÇÃO DE IMÓVEIS

O preço de um imóvel pode ser entendido como a soma dos valores implícitos de suas características, como área, número de dormitórios e localização. Essa ideia, formalizada pela teoria dos preços hedônicos, sustenta a maior parte dos modelos estatísticos de avaliação imobiliária (Rosen, 1974). No Brasil, a norma de avaliação de imóveis urbanos admite o uso de modelos de inferência estatística para estimar valores de mercado, desde que se demonstre a qualidade do ajuste aos dados (ABNT, 2011).

No contexto local, Reza *et al.* (2025) estudaram os fatores que influenciam o preço de apartamentos anunciados em Chapecó por meio de regressão múltipla com o logaritmo do preço como variável dependente, e concluíram que a área útil, o número de quartos e a disponibilidade de garagem estão entre os principais determinantes. Em revisão das pesquisas publicadas entre 2018 e 2023, Ferreira (2024) identificou o crescimento do uso de redes neurais e de algoritmos supervisionados para prever preços de imóveis, com desempenho frequentemente superior ao dos modelos hedônicos lineares, e apontou a escassez de estudos brasileiros sobre o tema. O mercado de Chapecó, por sua vez, é marcado pelo crescimento urbano e pela expansão da produção imobiliária, característicos de cidades médias (Silva, 2023).

Para acompanhar a evolução dos preços ao longo do tempo, o Índice FipeZap utiliza anúncios publicados na internet, estratificados por localização e número de dormitórios, mas não contempla Chapecó (FIPE, 2023). Uma alternativa clássica para medir valorização é comparar o preço do mesmo imóvel em dois momentos, técnica conhecida como vendas repetidas, que elimina as diferenças de tamanho e padrão entre imóveis distintos (Bailey; Muth; Nourse, 1963; Case; Shiller, 1989). Essa técnica, entretanto, depende de um histórico longo de preços do mesmo bem, o que não existe quando os dados são coletados por poucos meses.

2.2 APRENDIZADO DE MÁQUINA PARA REGRESSÃO

O aprendizado de máquina reúne métodos que permitem a um programa aprender padrões a partir de exemplos, sem que cada regra seja programada explicitamente (Russell; Norvig, 2022). A estimativa de preços é um problema de aprendizado supervisionado do tipo regressão, pois o modelo aprende a partir de imóveis com preço conhecido para prever um valor numérico contínuo (James *et al.*, 2021).

Os modelos lineares são o ponto de partida mais simples. A regressão linear múltipla estima um peso para cada variável e é fácil de interpretar, mas supõe que o preço seja uma soma linear das características (Hastie; Tibshirani; Friedman, 2009). As versões regularizadas Ridge e Lasso acrescentam uma penalidade ao tamanho dos pesos, o que estabiliza o modelo quando as variáveis são correlacionadas entre si, e no caso do Lasso pode zerar variáveis pouco úteis (Hoerl; Kennard, 1970; Tibshirani, 1996).

Os modelos baseados em árvores de decisão capturam relações não lineares e interações entre variáveis. O Random Forest treina muitas árvores em amostras aleatórias dos dados e faz a média das previsões, o que o torna robusto a valores atípicos (Breiman, 2001). O *gradient boosting*, por sua vez, constrói as árvores em sequência, cada uma corrigindo o erro das anteriores (Friedman, 2001). Duas implementações desse princípio se destacam em dados tabulares: o XGBoost, que acrescenta regularização e amostragem para treinar de forma rápida e estável (Chen; Guestrin, 2016), e o CatBoost, que trata variáveis categóricas, como o bairro, de forma a reduzir o vazamento de informação do alvo durante o treino (Prokhorenkova *et al.*, 2018).

Também foram considerados métodos de outras famílias. As redes neurais do tipo perceptron multicamadas combinam as variáveis em camadas de neurônios e podem representar padrões complexos, mas costumam exigir mais dados e ajuste cuidadoso (Géron, 2021). A regressão por vetores de suporte busca uma função que passe a uma distância tolerada da maioria dos pontos e é sensível à escala das variáveis e do alvo (Drucker *et al.*, 1997). Mais recentemente, o TabPFN propôs um modelo pré-treinado em milhões de tabelas sintéticas, capaz de prever em bases pequenas sem ajuste de parâmetros (Hollmann *et al.*, 2025).

2.3 AVALIAÇÃO DE MODELOS

Para que o erro medido represente o desempenho em imóveis novos, os dados de teste devem ser separados antes de qualquer decisão de modelagem, e a escolha entre candidatos deve ser feita por validação cruzada dentro do conjunto de treino (Kohavi, 1995). Quando um mesmo objeto aparece em várias linhas da base, todas as suas linhas precisam ficar do mesmo lado da divisão, caso contrário o modelo é avaliado em exemplos que já viu (Hastie; Tibshirani; Friedman, 2009).

As métricas usuais em regressão são o erro médio absoluto (MAE), que expressa o erro típico em reais; a raiz do erro quadrático médio (RMSE), que penaliza mais os erros grandes; e o coeficiente de determinação (R^2), que indica a fração da variação dos preços explicada pelo modelo (James *et al.*, 2021). O erro percentual absoluto médio (MAPE) é intuitivo, mas torna-se instável quando há valores reais muito pequenos, situação comum em bases com erros de cadastro; nesses casos, o erro percentual absoluto mediano (MdAPE) é uma alternativa robusta (Hyndman; Koehler, 2006). Para

medir a incerteza de uma estimativa, a reamostragem *bootstrap* sorteia repetidamente os dados com reposição e observa a variação do resultado (Efron; Tibshirani, 1993). Já a teoria da credibilidade fornece uma forma de combinar uma estimativa baseada em poucos dados com uma referência mais estável, dando a cada uma um peso proporcional à quantidade de informação disponível (Bühlmann; Gisler, 2005).

3 PROCEDIMENTOS METODOLÓGICOS

3.1 TIPO E ABORDAGEM DA PESQUISA

Quanto à natureza, a pesquisa é aplicada, pois busca resolver um problema prático: estimar o valor de imóveis em um município específico. Quanto à abordagem, é quantitativa, uma vez que se baseia em dados numéricos e em técnicas estatísticas e computacionais. Quanto aos objetivos, é exploratória e descritiva, por investigar um tema pouco estudado no contexto local e descrever os padrões encontrados nos dados (Gil, 2002). Quanto aos procedimentos, trata-se de pesquisa documental, por usar anúncios publicados na internet e séries oficiais de índices econômicos, e experimental, por comparar modelos sob as mesmas condições controladas (Prodanov; Freitas, 2013).

O desenvolvimento seguiu o CRISP-DM (*Cross-Industry Standard Process for Data Mining*), modelo de processo que divide um projeto de mineração de dados em seis fases: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação (Chapman *et al.*, 2000; Shearer, 2000). As fases não são lineares, e o resultado de uma delas pode exigir o retorno a uma anterior. Foi o que aconteceu neste trabalho: a avaliação das primeiras versões mostrou que os anúncios não permitiam medir a valorização, e a preparação dos dados precisou ser refeita. O Quadro 1 relaciona cada fase às atividades realizadas e às seções em que elas são descritas.

Quadro 1 – Fases do CRISP-DM e atividades realizadas neste trabalho

Fase	**Atividades realizadas**	**Seções**
Entendimento do negócio	Definição do problema, das perguntas de pesquisa, dos critérios de sucesso e das restrições	3.2
Entendimento dos dados	Coleta por *web scraping*, descrição dos campos, identificação das lacunas e análise exploratória	3.3 e 4.1
Preparação dos dados	Unificação, padronização, deduplicação, limpeza, divisão em treino e teste e construção do histórico simulado	3.4 e 4.2
Modelagem	Treino de 22 candidatos e de um *ensemble*, com escolha por validação cruzada	3.5 e 4.3
Avaliação	Medida do erro no teste com preços reais, coerência com o índice e projeção da valorização	4.3 e 4.4
Implantação	Publicação dos modelos em uma interface web	4.5

Fonte: Elaborado pela autora (2026), com base em Chapman *et al.* (2000).

3.2 ENTENDIMENTO DO NEGÓCIO

O problema de negócio é a falta de uma referência de preços de imóveis em Chapecó: quem compra, vende ou investe depende da opinião de corretores, e os índices de preços existentes não cobrem o município. Traduzido para a mineração de dados, o problema tem duas partes. A primeira

é uma regressão: estimar o preço de uma casa ou de um apartamento a partir de suas características. A segunda é temporal: estimar quanto esse imóvel valia nos anos anteriores e quanto pode valer nos próximos. Como critérios de sucesso, definiu-se que o erro deveria ser medido em termos percentuais, para ser comparável entre imóveis baratos e caros, e que os resultados deveriam ser publicados em uma interface gratuita e de fácil uso. As restrições conhecidas desde o início eram a ausência de dados de vendas efetivas, que não são públicos, o prazo de poucos meses para a coleta e a hospedagem gratuita, que limita o tamanho dos modelos publicados.

3.3 ENTENDIMENTO DOS DADOS: INSTRUMENTO DE COLETA

O instrumento de coleta foi um conjunto de programas em Python que extraem automaticamente os anúncios de venda de oito imobiliárias de Chapecó. Quatro delas tiveram as páginas HTML lidas diretamente e quatro forneceram os dados por meio de interfaces de programação (APIs) usadas pelos próprios sites (Mitchell, 2018). Foram feitas doze coletas entre 23 de março e 2 de agosto de 2026, cada uma gravada em um banco SQLite datado. Além dos anúncios, foram obtidas as séries mensais oficiais do Índice Nacional de Preços ao Consumidor Amplo (IPCA, série 433) e do Índice Nacional de Custo da Construção (INCC, série 192) no Sistema Gerenciador de Séries Temporais do Banco Central do Brasil (Banco Central do Brasil, 2026).

O Quadro 2 descreve os campos coletados, com a proporção de casas e apartamentos em que cada um estava vazio e o uso que teve no trabalho. Os campos de texto, como o bairro e o tipo, foram preenchidos livremente por cada imobiliária, o que exigiu padronização.

Quadro 2 – Campos coletados nos anúncios de casas e apartamentos

Campo	Descrição	Vazio	Uso
Preço	Valor pedido no anúncio, em reais	0,0%*	Variável a prever (alvo)
Bairro	Texto livre, com grafias diferentes entre as imobiliárias	1,8%	Entrada (categórica)
Tipo	Texto livre, como “Apto” ou “Sobrado”	–	Separa casas e apartamentos
Área total e privativa	Em m^2	2,1%	Entrada (numérica)
Quartos, banheiros e vagas	Quantidades	2,9%, 9,1% e 12,5%	Entrada (numérica)
Data da coleta	Data do banco de cada coleta	0,0%	Acompanhamento do preço no tempo
Endereço	Rua e número	100%	Não utilizado

*Anúncios sem preço foram descartados na preparação.

Fonte: Elaborado pela autora (2026).

Já nessa fase ficaram claras as lacunas da base, isto é, informações que influenciam o preço, mas não puderam ser obtidas: o endereço, ausente em todos os anúncios, o que restringe a localização ao bairro; a idade, o padrão de acabamento e o estado de conservação, que as imobiliárias não publicam de forma estruturada; as fotos, cujo endereço não foi guardado nas coletas; e o preço efetivo de venda, já que o anúncio mostra apenas o valor pedido. Além disso, as coletas cobrem de março a agosto de 2026, e não há nenhum preço anterior a esse período. A análise exploratória (seção 4.1) mostrou ainda

que o preço anunciado quase não muda entre as coletas, o que tornou essa lacuna temporal o principal obstáculo do trabalho.

3.4 PREPARAÇÃO DOS DADOS: TABULAÇÃO

3.4.1 Unificação, padronização e limpeza

A Tabela 1 apresenta as etapas da preparação na ordem em que foram aplicadas, com a técnica usada e a quantidade de imóveis restante. As etapas 1 a 5 não dependem da distribuição dos preços e foram aplicadas à base inteira. As etapas 8 a 10, ao contrário, usam limites calculados a partir dos dados e, por isso, foram aprendidas somente no treino e depois aplicadas ao teste. Na primeira versão do trabalho, os valores atípicos eram removidos antes da divisão, o que deixava o teste artificialmente "limpo" e o erro menor do que o real; essa falha foi corrigida com a ordem descrita. A manipulação foi feita com a biblioteca pandas (McKinney, 2018).

Tabela 1 – Etapas da preparação dos dados

Etapa	Técnica aplicada	Resultado
1. Unificação	Junção dos 12 bancos; cada imóvel identificado pelo código do anúncio, com uma tabela do preço em cada coleta	46.383 registros → 4.971 imóveis
2. Padronização	Grafias de bairro e de cidade unificadas; tipos de texto livre mapeados para um catálogo fixo (Apartamento, Casa, Terreno, Chácara etc.)	–
3. Deduplicação	Anúncios do mesmo imóvel em imobiliárias diferentes agrupados por cidade, tipo, área arredondada, quartos, banheiros, vagas e bairro; preço e áreas pela mediana do grupo	4.266 imóveis (451 consolidados)
4. Escopo	Mantidos apenas casas e apartamentos; terrenos e chácaras têm preço ligado à terra, e não à construção	3.354 imóveis
5. Campos vazios	Descartados os anúncios sem preço ou sem área; quartos, banheiros e vagas vazios preenchidos com zero	3.283 (1.896 apartamentos e 1.387 casas)
6. Mês de referência	Preços levados a agosto de 2026 pelo índice IPCA+INCC (ajuste de até cerca de 2,5%)	–
7. Treino e teste	Divisão de 80% e 20% por imóvel, com semente fixa, antes das etapas seguintes	Apartamentos 1.516 e 380; casas 1.109 e 278
8. Bairros raros	Bairros com menos de dez imóveis no treino agrupados em "outros"	26 de 49 bairros (apartamentos) e 50 de 78 (casas)
9. Valores extremos	Variáveis numéricas limitadas aos percentis de 2% e 98% do treino	Ex.: de 1 a 4 quartos em apartamentos
10. Valores atípicos	Removidos do treino os imóveis fora de 1,5 intervalo interquartil do preço ou do preço por m^2	Treino com 1.400 apartamentos (−116) e 1.039 casas (−70)
11. Histórico simulado	Dez registros por imóvel de treino, um por ano de 2016 a 2025 (seção 3.4.2)	Treino com 15.400 e 11.429 linhas

Fonte: Elaborada pela autora (2026).

O teste não passa pela etapa 10, para que o erro seja medido também nos anúncios estranhos. Os resultados principais usam os imóveis de teste dentro dos limites aprendidos no treino (357 apartamentos e 261 casas), e o efeito de manter os demais é mostrado na seção 4.3. Para a análise exploratória, em vez das etapas 7 a 11, foram mantidos os 3.242 imóveis com preço entre R$ 50 mil e R$ 20 milhões e área entre 20 m^2 e 2.000 m^2, para que os erros de cadastro não distorcessem os gráficos.

3.4.2 Do primeiro modelo ao histórico simulado

A preparação foi refeita três vezes, à medida que a modelagem e a avaliação revelavam problemas. Na primeira versão (v1), o modelo de preço foi treinado só com os anúncios reais, e a valorização foi medida pela variação do preço anunciado do mesmo imóvel entre as coletas. As primeiras rodadas, com todos os tipos de imóvel juntos e sem limpeza, tiveram R^2 próximo de zero, e os modelos lineares chegaram a erros de trilhões de reais por causa dos erros de cadastro; separar casas e apartamentos e remover os valores atípicos melhorou mais o resultado do que trocar de algoritmo. O problema mais sério apareceu na valorização: como 95,9% dos preços não mudaram entre coletas (seção 4.1), a taxa medida foi de +0,89% ao ano para apartamentos e +0,38% para casas, bem abaixo da inflação, e o modelo não tinha como dizer quanto um imóvel valia antes de 2026.

Na segunda versão (v2), tentou-se aproximar os valores com índices oficiais. Corrigir os preços de treino pelo IPCA mudou cada preço em no máximo 1,2%, e o erro do modelo de preço praticamente não se alterou, porque a correção não traz informação nova sobre qual imóvel vale mais. Na valorização, a taxa medida passou a ser combinada com um índice de referência, primeiro o IPCA e depois o IVG-R, índice do Banco Central baseado nas avaliações de imóveis financiados, o que elevou a estimativa para algo entre +2,9% e +3,8% ao ano. O modelo de preço, porém, continuava sem a dimensão do tempo: estimava o valor de hoje, e o passado era uma conta feita à parte.

A terceira versão (v3), apresentada neste artigo, levou o tempo para dentro dos dados. Como não existem preços passados observados, foi construído um histórico simulado, isto é, um conjunto de dados sintéticos gerado por uma regra explícita. Primeiro, foi criado um índice com a média simples das variações mensais do IPCA e do INCC. A lógica é que o terreno e o imóvel como um todo tendem a acompanhar a inflação geral, enquanto a construção tende a acompanhar o custo de construir. Com esse índice, todos os preços reais foram levados ao mês de referência (agosto de 2026), etapa necessária porque, sem ela, o modelo confundia a diferença entre imóveis anunciados em meses diferentes de 2026 com valorização. Em seguida, para cada imóvel, foram gerados dez registros simulados, um para junho de cada ano entre 2016 e 2025:

$$P_{\text{jun}/Y} = \frac{P_{\text{ref}}}{I_{\text{ref}} / I_{\text{jun}/Y}} \tag{1}$$

em que P_{ref} é o preço no mês de referência e I é o nível do índice. Os registros simulados repetem as características do imóvel real e recebem o ano como variável adicional, como mostra o exemplo da Tabela 2. Assim, a base completa passou a ter 3.283 linhas reais e 32.830 simuladas, e cada imóvel de treino entrou no modelo com onze linhas. Os índices são valores oficiais, mas o passado de cada imóvel é uma hipótese: supõe-se que ele tenha acompanhado o índice.

3.5 TÉCNICA DE ANÁLISE DOS DADOS: MODELAGEM, AVALIAÇÃO E IMPLANTAÇÃO

A análise começou pela estatística descritiva e pela análise exploratória (Tukey, 1977), cujos resultados (seção 4.1) orientaram as decisões de modelagem. Casas e apartamentos foram modelados separadamente, com as bases de treino e de teste descritas na Tabela 1.

Foram comparados nove algoritmos (Regressão Linear, Ridge, Lasso, Random Forest, Gradient

Tabela 2 – Linhas de um apartamento real na base de modelagem

Linha	Data	Origem do preço	Preço (R$)
Real	ago/2026	Anúncio de mar/2026 (R$ 724.500) levado a ago/2026	743.116
Simulada	jun/2025	Equação 1	699.430
Simulada	jun/2021	Equação 1	546.208
Simulada	jun/2016	Equação 1	420.636

Apartamento no Centro com 77 m^2 privativos, 2 quartos, 1 banheiro e 2 vagas, iguais em todas as linhas. As demais linhas simuladas (2017 a 2020 e 2022 a 2024) seguem a mesma regra.

Fonte: Elaborada pela autora (2026).

Boosting, XGBoost, CatBoost, rede neural MLP e SVM), cada um com o alvo em preço e em logaritmo do preço, implementados com scikit-learn (Pedregosa *et al.*, 2011), XGBoost e CatBoost, e o TabPFN (Hollmann *et al.*, 2025), com o alvo em preço, em três versões executadas localmente (v2, 3.5 e 3.5 Fast) e na versão 3.5 executada no servidor do fabricante, por meio de sua API (Prior Labs, 2026), totalizando 22 candidatos. O ranking foi feito por validação cruzada de cinco partes agrupada por imóvel, de modo que o preço real e os simulados de um mesmo imóvel ficassem sempre juntos, e o erro foi medido apenas nas linhas reais. O critério de escolha foi o menor MdAPE; em caso de empate (mesmo MdAPE com uma casa decimal), venceu o menor MAE. Entre os candidatos que rodam na própria interface web (Random Forest, CatBoost, XGBoost, Gradient Boosting e Ridge), os três melhores foram combinados em um *ensemble*, com pesos inversamente proporcionais ao MdAPE, que concorreu como mais um candidato. A avaliação final usou o conjunto de teste, que não participou de nenhuma escolha, com MAE, RMSE, R^2 e MdAPE. O MAPE foi descartado porque erros de cadastro, como uma casa anunciada por "R$ 1,35", geram erros de milhões de por cento.

O TabPFN foi concebido para bases pequenas (a versão v2, por exemplo, para até cerca de 10 mil linhas), e o treino com o histórico simulado tem 11.429 linhas (casas) e 15.400 (apartamentos). Por isso, as versões locais foram executadas em processador comum, em tentativas sucessivas com todas as linhas, 10 mil e 3 mil linhas sorteadas, cada uma interrompida se não terminasse em 60 minutos; valeu a primeira tentativa concluída. Em casas, a tentativa com 10 mil linhas foi dispensada, pois cada parte da validação já treinava com 9.143 linhas. Executado localmente, o TabPFN não pode ser publicado, porque exige bibliotecas pesadas e levou cerca de dois minutos e meio para uma única previsão. Pela API, o mesmo modelo usa todas as linhas e responde em segundos, ao custo de enviar os dados de treino e as características do imóvel consultado ao servidor do fabricante; se a API não responder, a interface usa como reserva o melhor modelo que roda nela. O Random Forest foi usado com 100 árvores, e não 400, porque o MdAPE variou menos de 0,2 ponto percentual e o modelo ficou quatro vezes menor, o que permitiu publicá-lo no plano gratuito de hospedagem.

A projeção do valor futuro combinou duas fontes. A primeira foi a variação do preço anunciado dos mesmos imóveis entre as coletas, por bairro e tipo, com os bairros de poucos dados puxados para a média do tipo pelo peso $n/(n + 30)$, em que n é o número de imóveis acompanhados, e com a incerteza estimada por *bootstrap* de 1.000 reamostragens por imóvel. A segunda foi o próprio índice IPCA+INCC. Pela teoria da credibilidade, os anúncios receberam peso $T/(T + 12)$, em que $T = 5$ meses de observação, o que resultou em 29% para os anúncios e 71% para o índice (Bühlmann; Gisler, 2005).

Por fim, os modelos foram publicados em uma interface web desenvolvida com Streamlit (Streamlit,

2026). O código-fonte completo, que permite reproduzir todos os resultados, está disponível em repositório público (Cazarotto, 2026). Ferramentas de inteligência artificial generativa foram utilizadas como apoio à programação e à revisão do código, sob supervisão da autora, que conferiu os resultados apresentados.

4 ANÁLISE DOS DADOS E RESULTADOS

4.1 ENTENDIMENTO DOS DADOS: ANÁLISE EXPLORATÓRIA

Apartamentos (45,6%) e casas (33,0%) somaram 78,6% da base normalizada e foram os dois tipos modelados; terrenos e chácaras ficaram de fora, pois seu preço depende principalmente da terra e não da construção. A Tabela 3 resume a distribuição dos preços. As casas custam mais no total, mas os apartamentos custam mais por metro quadrado, já que parte da área das casas é terreno.

Tabela 3 – Distribuição de preços de casas e apartamentos

	Apartamento	**Casa**
Imóveis	1.880	1.362
Preço: 10% mais baratos até	R$ 320 mil	R$ 450 mil
Preço mediano	R$ 690 mil	R$ 1,00 milhão
Preço: 10% mais caros a partir de	R$ 1,50 milhão	R$ 2,49 milhões
Área mediana	87 m^2	200 m^2
Preço por m^2 mediano	R$ 7.423	R$ 5.848

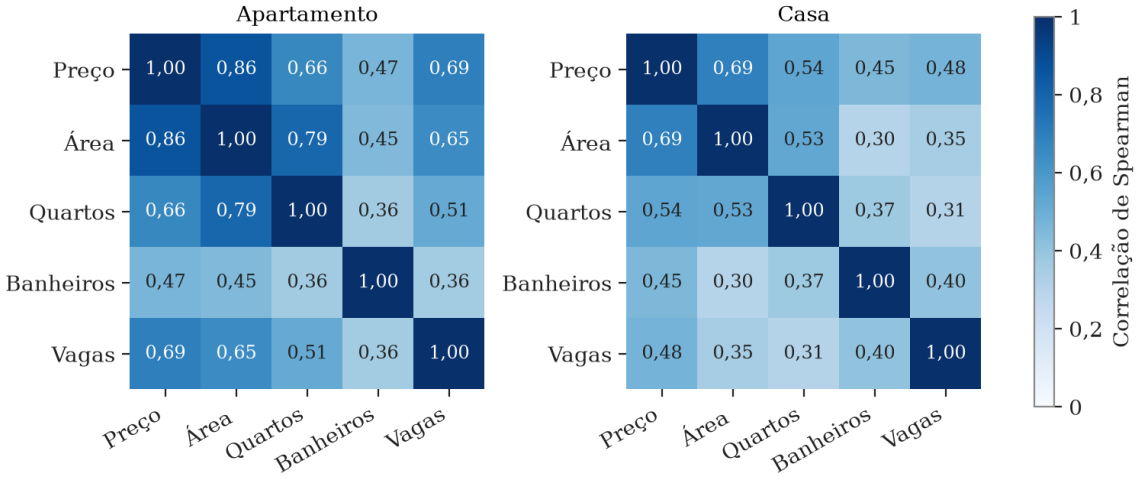
Fonte: Elaborada pela autora (2026).

A distribuição do preço é muito assimétrica, com coeficiente de assimetria de 3,5 em apartamentos e 3,9 em casas; em escala logarítmica, ele cai para 0,3 (Figura 2). Por isso, todos os algoritmos foram testados também com o alvo em logaritmo. A correlação de Spearman, que mede se duas variáveis crescem juntas mesmo sem relação linear, foi de 0,86 entre a área e o preço em apartamentos e de 0,69 em casas, seguida por vagas (0,69 e 0,48) e quartos (0,66 e 0,54), como mostra a Figura 1. As variáveis de entrada também são correlacionadas entre si, como a área e os quartos (0,79 em apartamentos), ou seja, parte da informação é repetida. Esses números confirmam, para um conjunto maior de imóveis, o que Reza *et al.* (2025) encontraram para apartamentos na cidade, e mostram que a área ordena muito melhor o preço de um apartamento do que o de uma casa. O preço por m^2 não sobe com o número de quartos, o que indica uma relação não linear entre as variáveis e o preço.

O bairro é a segunda informação mais importante. O preço por m^2 de apartamentos varia até 70% entre os bairros listados, com Maria Goretti (R$ 9.465), Centro (R$ 8.412), Presidente Médici e Jardim Itália entre os mais caros (Figura 3). A análise também encontrou erros de cadastro: 19 imóveis com preço abaixo de R$ 50 mil, como uma casa de 420 m^2 anunciada por “R$ 1,35”, e 89 com área abaixo de 20 m^2. Nenhuma variável informa o padrão de acabamento, a idade ou o estado de conservação, o que explica parte do erro que permanece nos modelos.

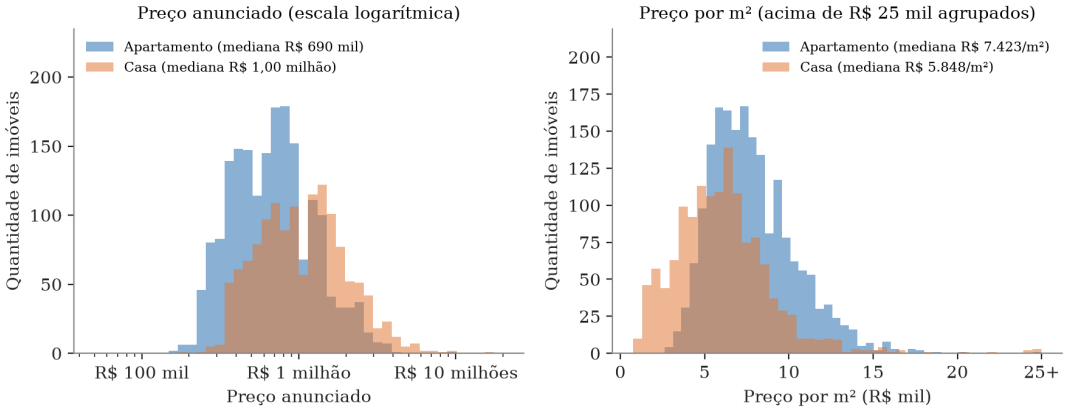
O comportamento no tempo foi o achado que mais influenciou o trabalho. Comparando o preço do mesmo imóvel entre coletas consecutivas (10.984 comparações), 95,9% não mudaram, 2,5% subiram e 1,5% caíram. Medida apenas pelos anúncios, a valorização foi de +0,89% ao ano em apartamentos e +0,38% em casas, muito abaixo da inflação do período. O preço anunciado é definido na entrada

Figura 1 – Correlação de Spearman entre as variáveis



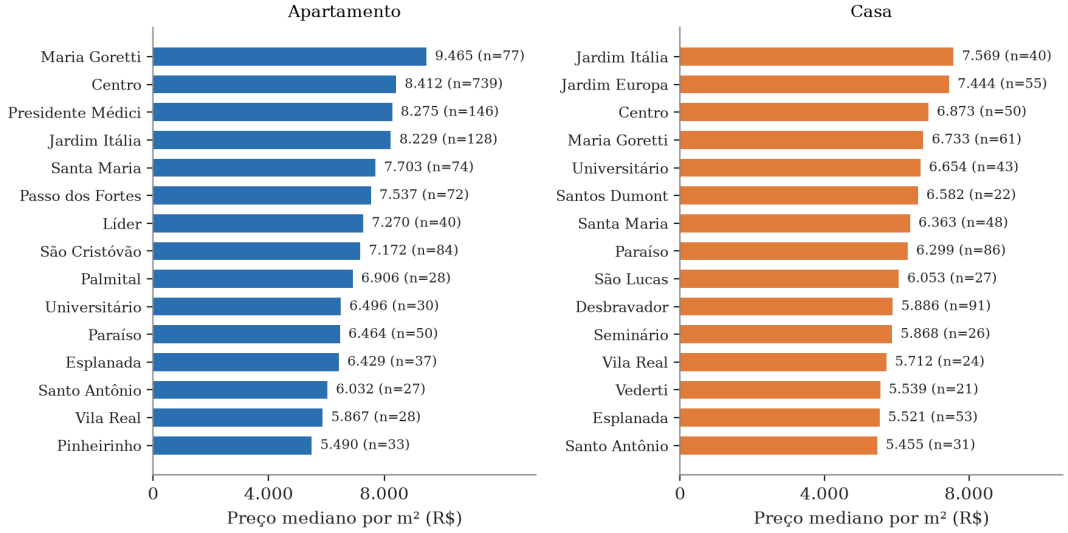
Fonte: Elaborada pela autora (2026).

Figura 2 – Distribuição dos preços de apartamentos e casas



Fonte: Elaborada pela autora (2026).

Figura 3 – Preço mediano por m² nos principais bairros



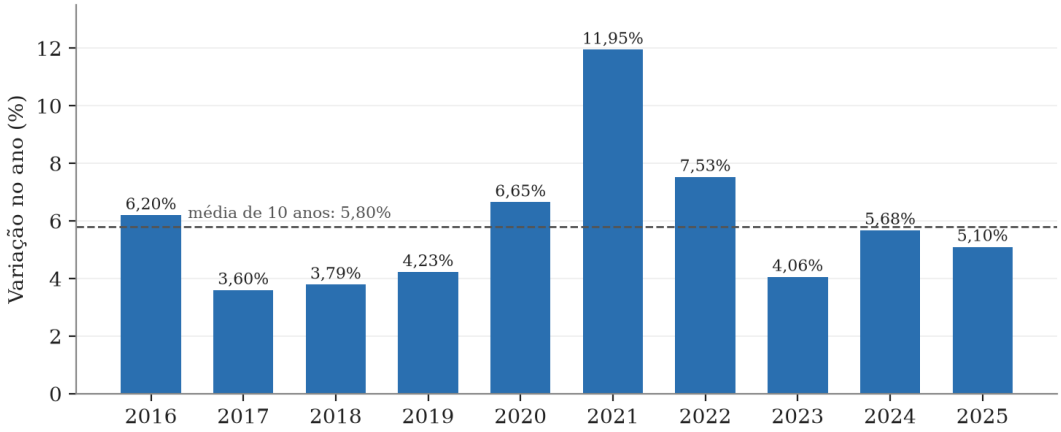
Fonte: Elaborada pela autora (2026).

do anúncio e raramente reajustado; além disso, os imóveis bem precificados são vendidos e saem da amostra. Esse comportamento motivou a construção do histórico simulado pelo índice IPCA+INCC (seção 3.4.2).

4.2 PREPARAÇÃO DOS DADOS: O ÍNDICE IPCA+INCC

Nos últimos dez anos, o índice combinado variou em média +5,80% ao ano, entre +3,60% em 2017 e +11,95% em 2021 (Figura 4). Nos últimos cinco anos, a média foi de +5,95% ao ano, contra +5,30% do IPCA e +6,60% do INCC isolados.

Figura 4 – Variação anual do índice IPCA+INCC



Fonte: Elaborada pela autora (2026), com dados do Banco Central do Brasil (2026).

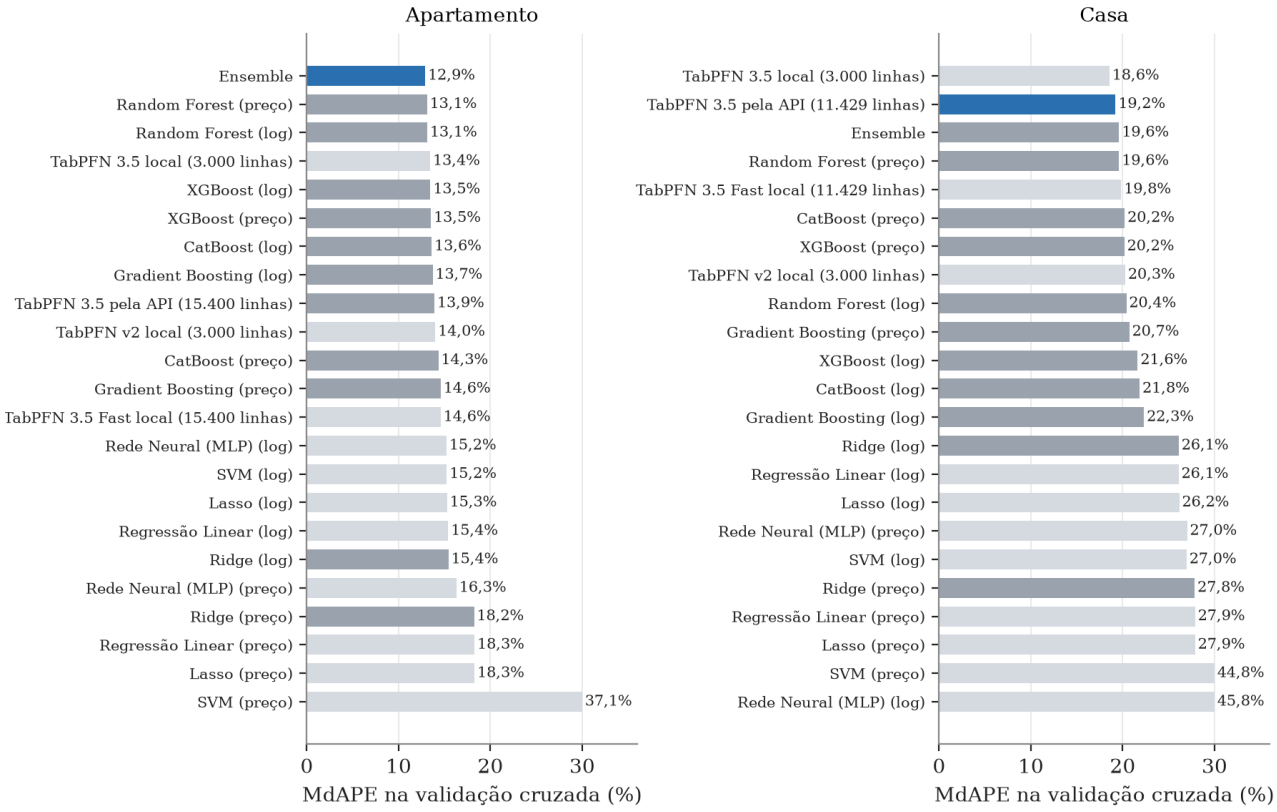
Antes de adotar o índice, foi testada a hipótese de que a taxa de juros explicaria a valorização. Com 25 anos de dados mensais do Banco Central e três períodos de teste, os modelos com Selic só superaram a média histórica no primeiro período (a partir de 2017); nos dois mais recentes, a média simples de dez anos foi melhor. Por isso, os juros não foram usados na projeção.

4.3 MODELAGEM E AVALIAÇÃO: COMPARAÇÃO DOS MODELOS

A Figura 5 apresenta os 22 candidatos e o *ensemble* na ordem do MdAPE da validação cruzada, e a Tabela 4 resume os principais no teste. Em apartamentos, o modelo publicado foi o *ensemble* de Random Forest com alvo em preço e em logaritmo e XGBoost com alvo em logaritmo. Em casas, foi o TabPFN 3.5 pela API, e a reserva é o *ensemble* de Random Forest, CatBoost e XGBoost, todos com alvo em preço. Os pesos ficaram próximos de um terço para cada modelo, porque os três tinham MdAPE quase igual.

Os modelos de árvores e o TabPFN foram os melhores nos dois tipos, o que é coerente com a análise exploratória: o preço não é uma soma linear das características, já que o efeito da área muda de um bairro para outro e o preço por m^2 não cresce com os quartos. Os primeiros colocados ficaram a menos de dois pontos percentuais de MdAPE uns dos outros. Em casas, o TabPFN 3.5 local liderou mesmo treinado com apenas 3 mil linhas, já que com todas as linhas não terminou dentro do limite de 60 minutos; a versão 3.5 Fast foi a única local que concluiu com todas as linhas, em 34 minutos (casas) e 55 minutos (apartamentos), com erro um pouco maior. Pela API, o TabPFN 3.5 usou todas as linhas

Figura 5 – MdAPE na validação cruzada dos 22 candidatos e do *ensemble*



Ordem: MdAPE na validação cruzada (empate decidido pelo MAE). Barras acima de 30% foram cortadas.
Azul: modelo do site; cinza-escuro: candidatos do site; cinza-claro: fora do site.

Fonte: Elaborada pela autora (2026).

Tabela 4 – Desempenho no teste (preços reais) dos principais modelos

Tipo	Modelo	MdAPE CV	MdAPE	MAE (R$)	R^2
Apartamento	*Ensemble* (site)	12,9%	13,1%	123.858	0,781
	Random Forest (preço)	13,1%	13,8%	127.120	0,767
	TabPFN 3.5 local (3 mil linhas)*	13,4%	13,6%	120.440	0,799
	XGBoost (log)	13,5%	14,4%	124.703	0,788
	TabPFN 3.5 pela API	13,9%	14,0%	118.922	0,800
	Regressão Linear (log)*	15,4%	15,2%	132.643	0,751
	SVM (preço)*	37,1%	39,3%	316.157	−0,333
Casa	TabPFN 3.5 local (3 mil linhas)*	18,6%	18,0%	293.164	0,559
	TabPFN 3.5 pela API (site)	19,2%	18,7%	302.336	0,540
	Ensemble (reserva)	19,6%	18,9%	300.285	0,558
	Random Forest (preço)	19,6%	19,6%	321.703	0,478
	CatBoost (preço)	20,2%	19,8%	295.389	0,583
	Regressão Linear (preço)*	27,9%	29,1%	364.199	0,414
	SVM (preço)*	44,8%	43,5%	536.632	−0,302

MdAPE CV: validação cruzada; demais colunas: teste. *Fora da interface web.

Fonte: Elaborada pela autora (2026).

e cada parte da validação levou poucos segundos; em casas, foi o melhor entre os modelos que podem ser publicados. Usar todas as linhas, porém, não melhorou o TabPFN: nos dois tipos, a versão local com 3 mil linhas teve MdAPE menor, o que sugere que as linhas simuladas, por repetirem o mesmo imóvel em outros anos, acrescentam pouca informação sobre o preço.

Em apartamentos, o Random Forest foi o melhor modelo isolado pelo MdAPE e formou, com o XGBoost, o *ensemble* publicado. Em casas, o CatBoost teve o maior R^2 no teste (0,583), embora tenha ficado atrás no MdAPE, o que pode ser associado ao tratamento que ele dá a variáveis categóricas como o bairro (Prokhorenkova *et al.*, 2018). Essa diferença mostra que MdAPE e R^2 medem aspectos distintos: o MdAPE reflete o erro no imóvel típico, enquanto o R^2 é dominado pelos imóveis caros, nos quais o Random Forest, em especial, erra mais. Os modelos lineares tiveram de 2 a 9 pontos percentuais a mais de MdAPE na validação do que o melhor candidato, e Ridge e Lasso tiveram praticamente o mesmo resultado da regressão linear, pois as poucas variáveis não causavam instabilidade a ser corrigida. A rede neural e o SVM ficaram entre os piores: com cerca de mil imóveis por tipo, há poucos exemplos para a rede, e o SVM com o alvo em reais obteve R^2 negativo, ou seja, pior do que prever a média. Em casas, o alvo em logaritmo piorou os modelos de árvores e a rede neural, porque o modelo passa a acertar o valor típico e subestima as casas caras, que concentram o erro em reais; já os modelos lineares e o SVM melhoraram com ele, pois o logaritmo torna a relação com as variáveis mais próxima de uma soma e reduz a escala do alvo.

Os modelos publicados obtiveram MdAPE de 13,1% em apartamentos e 18,7% em casas no teste, com R^2 de 0,781 e 0,540, um pouco abaixo dos de uma versão treinada apenas com os anúncios reais (0,795 e 0,559), em parte porque a escolha pelo MdAPE privilegia o acerto no imóvel típico, e não nos mais caros. Essa proximidade era esperada, pois o histórico simulado não traz informação nova sobre qual imóvel vale mais; o ganho está em permitir que o modelo responda quanto o imóvel valia em anos anteriores. Na prática, o valor estimado ficou a menos de 20% do preço anunciado em 66,1% dos apartamentos e 52,5% das casas de teste. A Figura 6 mostra que os modelos tendem a subestimar os imóveis mais caros, para os quais há menos exemplos na base.

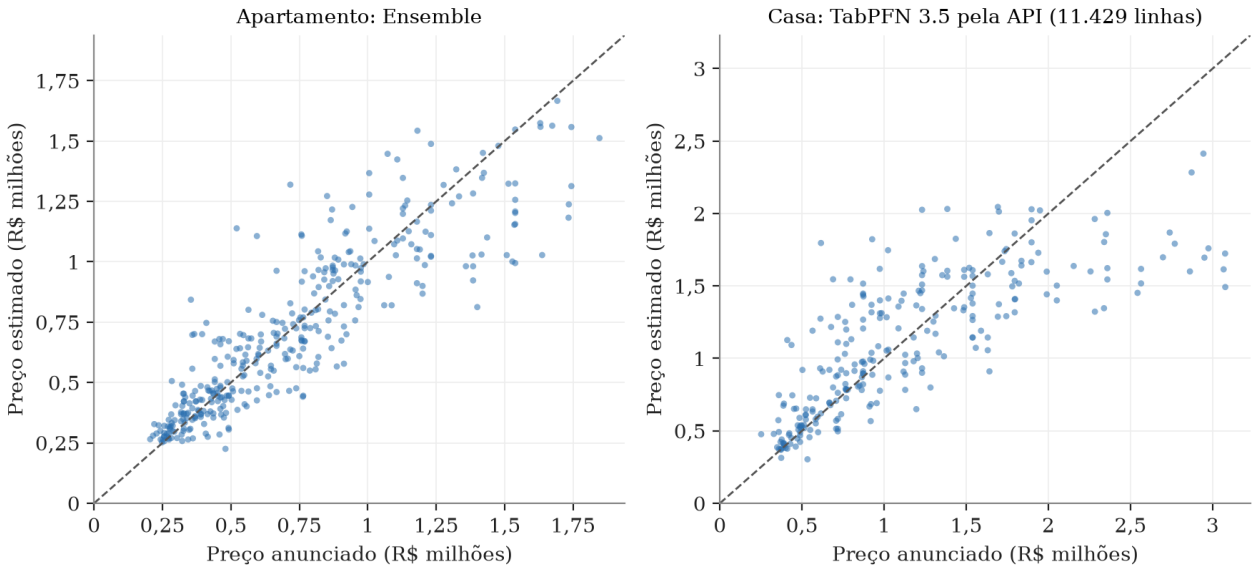
A diferença entre os tipos também foi coerente com os dados. Casas reúnem imóveis muito diferentes sob o mesmo rótulo, como sobrados, casas geminadas e casas em terrenos grandes, e a área explica menos o seu preço. Quando os anúncios com erros de cadastro foram mantidos no teste, o R^2 caiu para 0,613 em apartamentos e 0,372 em casas, o que mostra o peso desses erros na base.

4.4 AVALIAÇÃO: VALORIZAÇÃO E PROJEÇÃO

Combinando os anúncios (29%) e o índice (71%), a valorização estimada foi de +4,33% ao ano para apartamentos, com faixa de +2,64% a +8,32%, e de +4,17% ao ano para casas, com faixa de +2,47% a +8,17%. Como coerência interna, o modelo estimou que os imóveis de teste valiam, em junho de 2021, 74,1% (apartamentos) e 74,4% (casas) do valor atual, contra 73,5% indicados pelo índice; essa comparação mostra que o modelo aprendeu o índice, mas não prova que o passado real tenha sido assim.

Como exemplo, um apartamento de 80 m^2 privativos e 100 m^2 de área total no Centro, com dois quartos, dois banheiros e uma vaga, foi estimado em cerca de R$ 691 mil em agosto de 2026. Com

Figura 6 – Preço estimado pelos modelos publicados em relação ao preço anunciado (teste)



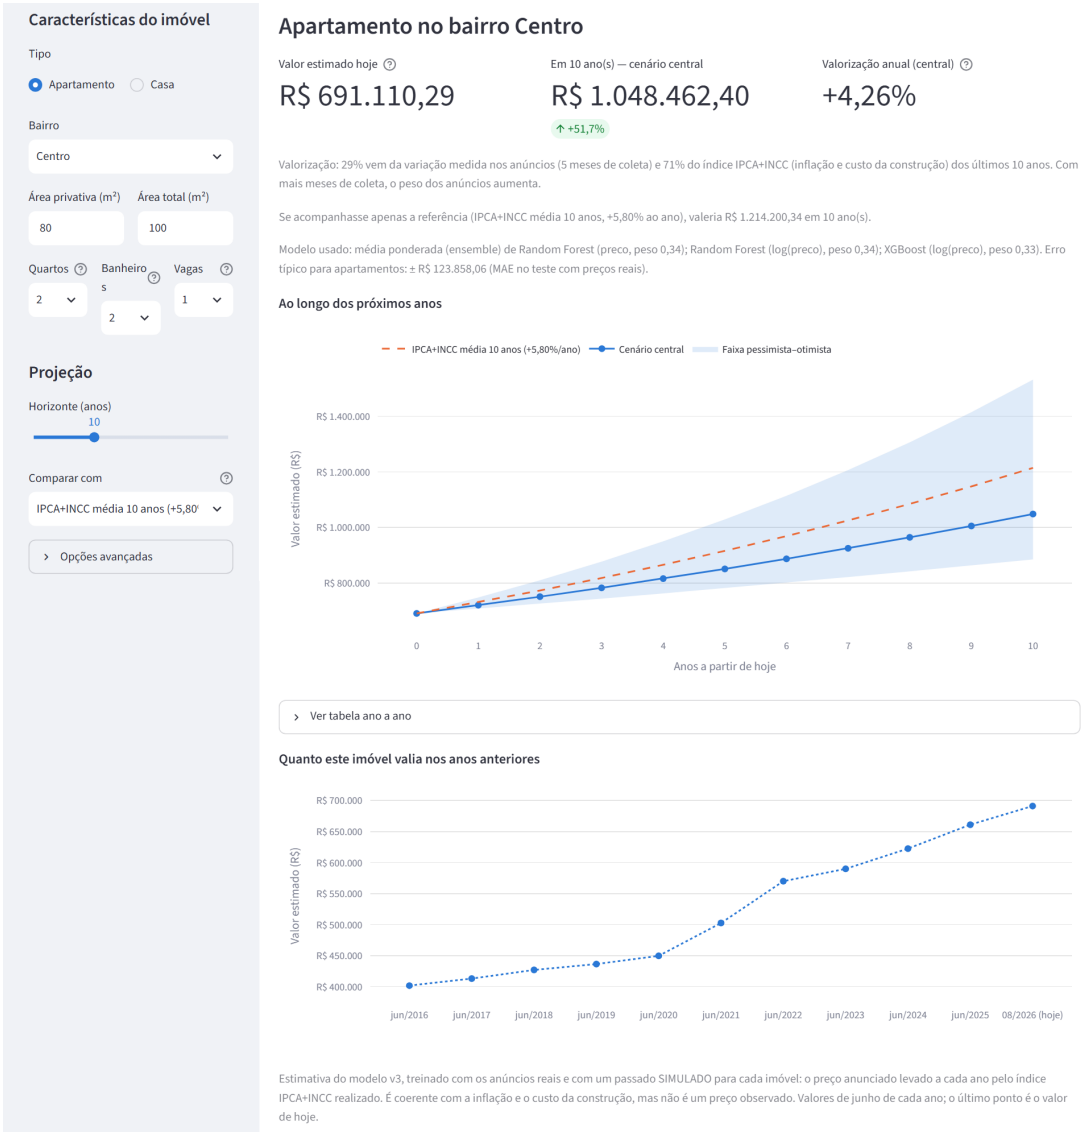
Fonte: Elaborada pela autora (2026).

a valorização do bairro (+4,26% ao ano), ele valeria cerca de R$ 1,05 milhão em dez anos, entre aproximadamente R$ 885 mil no cenário pessimista e R$ 1,53 milhão no otimista.

4.5 IMPLANTAÇÃO: INTERFACE WEB

Os resultados foram disponibilizados em uma interface web pública, acessível em `https://scrapping-estates-ayzubn6w4uizag9pbeh5yq.streamlit.app`. Na aba de estimativa, o usuário informa o tipo, o bairro, a área, os quartos, os banheiros e as vagas, e recebe o valor estimado para hoje, a evolução de 2016 até hoje e a projeção para os próximos anos nos três cenários, além de avisos quando os dados informados estão fora do padrão da base. A interface informa qual modelo fez a estimativa e, no caso das casas, avisa que as características informadas, sem nenhum dado pessoal, são enviadas à API do TabPFN; as estimativas ficam em memória para que consultas repetidas não consumam a cota mensal da API. A Figura 7 mostra essa aba para o apartamento do exemplo da seção anterior, com o valor de hoje, a projeção e o passado simulado. As demais abas mostram a valorização por bairro, o ranking pelo MdAPE, as tentativas do TabPFN, a explicação de cada modelo com o motivo do seu resultado e o conjunto de dados utilizado, com os imóveis reais e o histórico simulado. Em relação aos protótipos planejados no TCC I, o painel com os coeficientes de cada variável foi substituído pela explicação dos modelos, já que os modelos de árvores e o TabPFN não possuem coeficientes diretamente interpretáveis.

Figura 7 – Aba de estimativa da interface web, para o apartamento do exemplo



Fonte: Elaborada pela autora (2026).

5 CONCLUSÃO

Este trabalho mostrou que é possível estimar o valor de casas e apartamentos em Chapecó a partir de anúncios coletados automaticamente, com erro típico de cerca de 13% para apartamentos e 19% para casas. Respondendo às questões de pesquisa, o desempenho foi aceitável para apartamentos e moderado para casas; a área e o bairro foram as variáveis mais influentes, seguidas de vagas e quartos; os modelos de árvores e o TabPFN apresentaram o melhor desempenho, com diferenças pequenas entre si, e, entre os que podem ser publicados, venceram o *ensemble* de Random Forest e XGBoost em apartamentos e o TabPFN pela API em casas, enquanto a rede neural e o SVM ficaram entre os piores para o volume de dados disponível.

O principal aprendizado foi que poucos meses de anúncios não medem valorização, porque o preço anunciado quase não muda. A solução adotada, simular o passado de cada imóvel com um índice formado por inflação e custo de construção, deu à projeção uma lógica econômica clara. Ainda assim, o passado simulado é uma hipótese, e não um preço observado, e assim deve ser apresentado até que

seja confirmado com dados reais.

Entre as limitações, destacam-se o uso do preço anunciado no lugar do preço de venda, a falta de endereço, idade e padrão construtivo dos imóveis, o número reduzido de imóveis de alto padrão e a falta de informações reais de compra e venda para testar a valorização estimada. Como trabalhos futuros, sugere-se reunir mais informações reais, como o valor de compra, de venda ou de avaliação de um mesmo imóvel em datas diferentes, para testar e validar o histórico simulado; manter a coleta por mais tempo para medir a valorização diretamente; e incluir informações sobre a idade e o padrão dos imóveis, por exemplo, a partir das fotos dos anúncios.

Por fim, a interface web publicada permite que qualquer pessoa consulte as estimativas e entenda como elas foram produzidas, o que cumpre o propósito de oferecer uma ferramenta transparente de apoio à decisão no mercado imobiliário local.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14653-2: avaliação de bens: parte 2: imóveis urbanos**. Rio de Janeiro: ABNT, 2011.

BAILEY, M. J.; MUTH, R. F.; NOURSE, H. O. A regression method for real estate price index construction. **Journal of the American Statistical Association**, v. 58, n. 304, p. 933–942, 1963.

BANCO CENTRAL DO BRASIL. **Sistema Gerenciador de Séries Temporais (SGS): séries 433 (IPCA) e 192 (INCC)**. 2026. Disponível em: https://www3.bcb.gov.br/sgspub/. Acesso em: 1 out. 2026.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

BÜHLMANN, H.; GISLER, A. **A course in credibility theory and its applications**. Berlin: Springer, 2005.

CASE, K. E.; SHILLER, R. J. The efficiency of the market for single-family homes. **The American Economic Review**, v. 79, n. 1, p. 125–137, 1989.

CAZAROTTO, A. C. L. **scrapping-estates: estimativa e projeção do valor de imóveis em Chapecó/SC**. 2026. Disponível em: https://github.com/anacazarotto/scrapping-estates. Acesso em: 28 out. 2026.

CHAPMAN, P. *et al.* **CRISP-DM 1.0: step-by-step data mining guide**. 2000. Disponível em: https://www.semanticscholar.org/paper/CRISP-DM-1.0%3A-Step-by-step-data-mining-guide-Chapman/54bad20bbc7938991bf34f86dde0babfbd2d5a72. Acesso em: 28 maio 2026.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. *In:* PROCEEDINGS of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016. p. 785–794.

DRUCKER, H. *et al.* Support vector regression machines. *In:* ADVANCES in Neural Information Processing Systems 9. Cambridge: MIT Press, 1997. p. 155–161.

EFRON, B.; TIBSHIRANI, R. J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993.

FERREIRA, H. T. **Inteligência artificial no mercado imobiliário: um cenário das pesquisas dos anos de 2018 até 2023**. 2024. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Civil) – Escola Politécnica, Pontifícia Universidade Católica de Goiás, Goiânia. Disponível em: https://repositorio.pucgoias.edu.br/jspui/handle/123456789/7983. Acesso em: 28 maio 2026.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.

FUNDAÇÃO INSTITUTO DE PESQUISAS ECONÔMICAS. **Índice FipeZap de venda residencial: metodologia e resultados**. 2023. Disponível em: https://www.fipe.org.br. Acesso em: 21 abr. 2026.

GÉRON, A. **Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow**. 2. ed. Rio de Janeiro: Alta Books, 2021.

GIL, A. C. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Atlas, 2002.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The elements of statistical learning: data mining, inference, and prediction**. 2. ed. New York: Springer, 2009.

HOERL, A. E.; KENNARD, R. W. Ridge regression: biased estimation for nonorthogonal problems. **Technometrics**, v. 12, n. 1, p. 55–67, 1970.

HOLLMANN, N. *et al.* Accurate predictions on small data with a tabular foundation model. **Nature**, v. 637, p. 319–326, 2025.

HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. **International Journal of Forecasting**, v. 22, n. 4, p. 679–688, 2006.

JAMES, G. *et al.* **An introduction to statistical learning: with applications in R**. 2. ed. New York: Springer, 2021.

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. *In:* PROCEEDINGS of the 14th International Joint Conference on Artificial Intelligence. Montréal: Morgan Kaufmann, 1995. p. 1137–1143.

MCKINNEY, W. **Python para análise de dados: tratamento de dados com pandas, NumPy e IPython**. São Paulo: Novatec, 2018.

MITCHELL, R. **Web scraping with Python: collecting more data from the modern web**. 2. ed. Sebastopol: O'Reilly Media, 2018.

PEDREGOSA, F. *et al.* Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PRIOR LABS. **TabPFN documentation**. 2026. Disponível em: https://docs.priorlabs.ai/. Acesso em: 1 nov. 2026.

PRODANOV, C. C.; FREITAS, E. C. de. **Metodologia do trabalho científico: métodos e técnicas da pesquisa e do trabalho acadêmico**. 2. ed. Novo Hamburgo: Feevale, 2013.

PROKHORENKOVA, L. *et al.* CatBoost: unbiased boosting with categorical features. *In:* ADVANCES in Neural Information Processing Systems 31. Montréal: Curran Associates, 2018.

REZA, G. S. *et al.* Fatores que influenciam a precificação de imóveis tipo apartamento na cidade de Chapecó-SC. **Revista Gestão & Análise**, Fortaleza, v. 14, n. 2, p. 159–167, 2025.

ROSEN, S. Hedonic prices and implicit markets: product differentiation in pure competition. **Journal of Political Economy**, v. 82, n. 1, p. 34–55, 1974.

RUSSELL, S.; NORVIG, P. **Inteligência artificial: uma abordagem moderna**. 4. ed. Rio de Janeiro: LTC, 2022.

SHEARER, C. The CRISP-DM model: the new blueprint for data mining. **Journal of Data Warehousing**, v. 5, n. 4, p. 13–22, 2000.

SILVA, É. da. **O mercado imobiliário em Chapecó/SC e Mossoró/RN: produção e consumo do espaço em cidades médias**. 2023. Trabalho de Conclusão de Curso (Bacharelado em Geografia) – Faculdade de Ciências e Tecnologia, Universidade Estadual Paulista "Júlio de Mesquita Filho", Presidente Prudente. Disponível em: https://repositorio.unesp.br/entities/publication/07e07f4c-fd22-47cc-bca1-851abb65bb31. Acesso em: 28 maio 2026.

STREAMLIT. **Streamlit documentation**. 2026. Disponível em: https://docs.streamlit.io/. Acesso em: 1 out. 2026.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 58, n. 1, p. 267–288, 1996.

TUKEY, J. W. **Exploratory data analysis**. Reading: Addison-Wesley, 1977.